Spatialisation du Q_{10} pour les modèles de surface terrestre

État d'avancement

Yassine Erraji William Peltier Simon Amar

Octobre 2026

Sommaire

1. Démarche et hypothèses
2. Les données
3. Protocole d'évaluation
4. Sélection des variables
5. Modèles comparés
6. Résultats
7. Piste explorée : données synthétiques
8. Vers la carte mondiale
9. Bilan critique et suite

Chaque titre est cliquable ; le lien « Sommaire » en bas de chaque slide ramène ici.

Le problème, en une slide

- ORCHIDEE utilise un Q_{10} **fixe** ($= 2.0$) pour la décomposition de la matière organique du sol.
- **Objectif** : une carte de Q_{10} qui fasse **mieux que 2.0 partout sur Terre**, pas seulement sur nos sites.
- **Point de départ** : Hacopian et al. (2026), régression linéaire $Q_{10} \sim \text{MAT} + \text{MAP} + \text{pH}$ et carte mondiale.
- **Difficulté centrale** : généraliser à toute la planète à partir de **131 sites**, très concentrés géographiquement.

Élément clé : toute la démarche consiste à juger chaque choix sur sa capacité à prédire **des régions jamais vues**.

Nos hypothèses de départ

H1 Le Q_{10} varie avec le climat, le sol et la végétation, et cette variation se prédit à partir de cartes mondiales.

H2 Ajouter des variables (sol, humidité du sol, végétation) améliore la prédiction par rapport à MAT + MAP + pH.

H3 Des modèles d'apprentissage automatique plus flexibles battent les modèles linéaires.

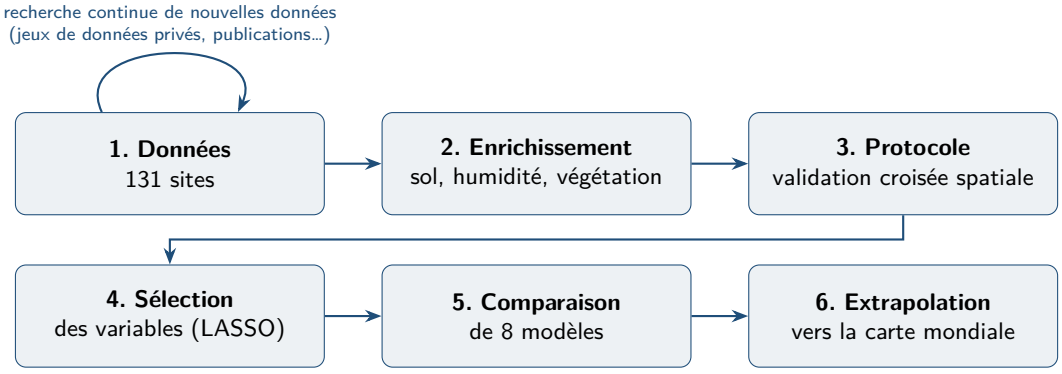
H4 Des données synthétiques peuvent compenser le faible nombre de sites.

H5 Les coordonnées (latitude, longitude) portent une information utile.

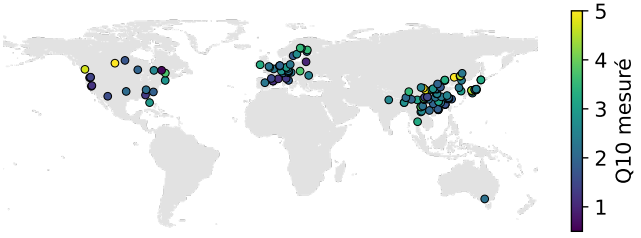
H6 Le type de végétation (biome) est un prédicteur important.

Élément clé : approche critique : plusieurs de nos hypothèses ont été réfutées, et nous le montrons.

Notre démarche



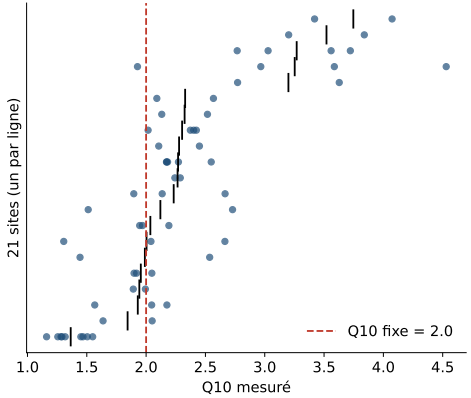
131 sites, très concentrés



- 173 mesures de Q_{10} microbien *in situ*, 6 sources (Hacopian 2026 et compléments de l'équipe).
- Mesures d'un même point GPS **agrégées** : 131 sites.
- **99 %** dans l'hémisphère Nord, **58 %** en Asie de l'Est, **7** sous les tropiques.
- **Aucun** site en Afrique ni en Amérique du Sud.

Élément clé : notre échantillon ne représente pas la planète : c'est la limite principale de tout le projet.

Un bruit local irréductible



- 21 sites portent plusieurs mesures (parcelles, peuplements, études) aux **mêmes variables** mais aux Q_{10} différents.
- Écart-type au sein d'un site : $\hat{\sigma}_{\text{intra}} \approx 0.45$, contre 0.96 au total.
- Aucune variable cartographiée ne peut expliquer cet écart : au mieux

$$R^2_{\max} \approx 1 - \frac{0.45^2}{0.96^2} \approx 0.78.$$

- **Décision** : une ligne par site (Q_{10} moyen), pour que chaque lieu pèse autant, comme sur une carte.

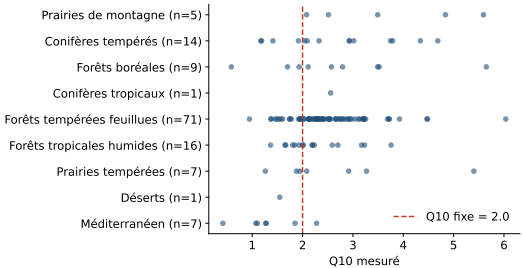
Élément clé : une part de la variabilité du Q_{10} est locale (essence, âge du peuplement, méthode) et restera inaccessible.

Variables explicatives : toutes disponibles en carte mondiale

Variable	Source	Définition
MAT, MAP	ERA5-Land 1995–2024	température de l'air à 2 m, précipitations annuelles
SWC moyen	ERA5-Land 1995–2024	humidité du sol 0–7 cm, moyenne annuelle
SWC été relatif	ERA5-Land 1995–2024	humidité des 3 mois les plus chauds / moyenne annuelle
pH	SoilGrids 2.0	0–5 cm
N, argile, sable, C:N	SoilGrids 2.0	5–15 cm, moyenne sur $\approx$ 15 km
Végétation	RESOLVE 2017	3 classes : forêts extratropicales, forêts tropicales, végétation ouverte
Latitude, longitude	—	coordonnées du site

- **Validation** : en recalculant MAT, MAP, N et SWC été relatif, on retrouve les valeurs du jeu de l'équipe (r de 0.98 à 0.996).
- **Écartées** : carbone organique (corrélé à 0.91 avec N) et température du sol (0.99 avec MAT), car redondants.

Ce que montrent les données



- Liens faibles pris isolément (Spearman) : MAT -0.30, N $+0.35$, longitude $+0.23$, SWC été relatif $+0.21$, MAP -0.04, pH -0.12.
- Comme chez Hacopian : Q_{10} élevé en prairies de montagne (médiane 3.49), plus bas en forêts tropicales humides (2.10).
- **Nouveau** : les sites méditerranéens ont le Q_{10} le plus bas (1.27) **et** l'été le plus sec (SWC été relatif 0.61, contre 0.94 à 1.11 ailleurs).

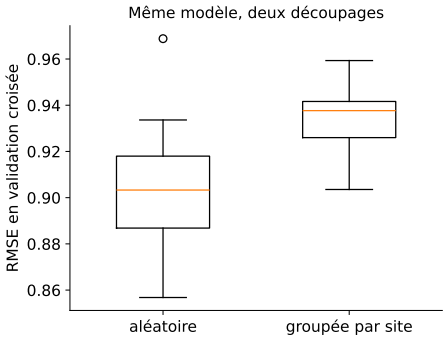
Élément clé : un été sec semble freiner la réponse des microbes à la chaleur ; d'où l'intérêt de l'humidité du sol.

Pourquoi une validation croisée « spatiale » ?

Validation croisée : on découpe les sites en K groupes, on entraîne sur $K-1$, on teste sur le dernier, et on tourne.

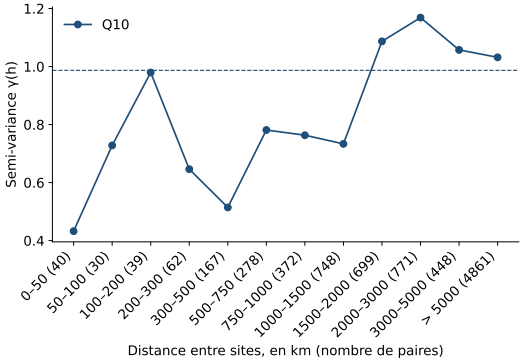
$$\mathrm{RMSE}_{\mathrm{CV}} = \frac{1}{K}\sum_{k=1}^{K}\sqrt{\frac{1}{|T_k|}\sum_{i\in T_k}\left(Q_{10,i} - \widehat{Q_{10,i}}\right)^2}$$

- Découpage **aléatoire** : un site de test a souvent un voisin presque identique à l'entraînement. Le score mesure en partie de la **mémoire**.
- Notre but est de prédire **des régions nouvelles** : on retire donc des zones géographiques entières.



Élément clé : un découpage aléatoire surestime la qualité d'un modèle (0.90 contre 0.93 ici).

Quelle taille de zone ? Le semi-variogramme



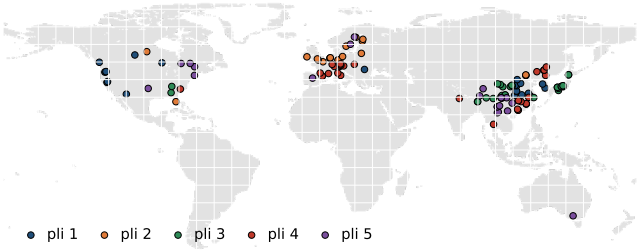
$$\gamma(h) = \tfrac{1}{2}\,\mathbb{E}\big[(Q_{10}(s) - Q_{10}(s+h))^2\big]$$

moyenne sur toutes les paires de sites distants de h

- Sous 50 km, $\gamma = 0.43$: moins de la moitié de la variance (0.99, pointillés).
- Jusqu'à $\approx$ 1 500 km, γ reste sous la variance : les sites se ressemblent encore. Au-delà, palier (1.03 à 1.17).
- **Pic à 100–200 km (0.98)** : 39 paires seulement ; les 3 qui contiennent le site au Q_{10} maximal (6.04) font la moitié de la somme. Sans ce site, $\gamma = 0.54$.
- **Palier au-dessus des pointillés** : la moyenne de γ sur toutes les paires vaut exactement la variance. Les 57 % de paires à plus de 5 000 km compensent donc les paires proches, sous la variance.
- **Choix** : zones de $10° \times 10°$ ($\approx$ 1 100 km en latitude), 37 zones.

Élément clé : les paires proches sont rares (1.3 % à moins de 200 km), d'où un début de courbe bruité. La portée ($\approx$ 1 500 km) repose sur $\approx$ 700 paires par classe.

Le découpage retenu



- 5 plis : chaque pli retire ≈ 7 zones entières (≈ 26 sites).
- Répété **20 fois** avec des découpages différents : 100 évaluations par modèle.
- **Mêmes découpages pour tous les modèles** : on peut les comparer pli par pli.
- Robustesse vérifiée avec des zones de $5°$.

Cible et métriques

Cible : $\log Q_{10}$. Si $R(T) = R_{\text{réf}}\, Q_{10}{}^{(T-T_{\text{réf}})/10}$, alors $\ln R = \beta_0 + \beta_1 T$ et $Q_{10} = e^{10\beta_1}$:

- $\log Q_{10} = 10\,\beta_1$ est directement la pente mesurée ;
- les prédictions $\widehat{Q_{10}} = \exp(\widehat{\log Q_{10}})$ restent positives, même en extrapolant ;
- la distribution devient plus symétrique (asymétrie $1.11 \to -0.68$). Une correction du biais de retransformation (Duan) a été testée : gain négligeable.

Métriques, toujours sur l'échelle de Q_{10} :

$$\text{RMSE} = \sqrt{\tfrac{1}{n}\textstyle\sum_i (Q_{10,i} - \widehat{Q_{10,i}})^2}, \quad \text{MAE} = \tfrac{1}{n}\textstyle\sum_i |Q_{10,i} - \widehat{Q_{10,i}}|, \quad R^2 = 1 - \frac{\sum_i (Q_{10,i} - \widehat{Q_{10,i}})^2}{\sum_i (Q_{10,i} - \overline{Q_{10}})^2}$$

$$\text{gain par rapport à 2.0} = 1 - \text{RMSE}_{\text{modèle}} / \text{RMSE}_{Q_{10}=2.0}$$

Comparer deux modèles honnêtement

- L'erreur varie beaucoup d'un pli à l'autre selon les régions retirées : l'erreur standard calculée sur les plis d'un seul modèle vaut ≈ 0.12, **plus que tous les écarts entre modèles**.
- On compare donc deux modèles A et B **sur les mêmes plis** : $d_k = \mathrm{RMSE}_k^A - \mathrm{RMSE}_k^B$.
- Les 100 plis ne sont pas indépendants (mêmes sites, entraînements qui se recouvrent). Correction de Nadeau et Bengio (2003) :

$$\widehat{\mathrm{SE}}(\bar{d}) = \sqrt{\left(\frac{1}{K} + \frac{n_{\text{test}}}{n_{\text{entraînement}}}\right) s_d^2}, \qquad K = 100,\ \frac{n_{\text{test}}}{n_{\text{entr.}}} \approx \frac{1}{4}.$$

- **Règle de choix**, fixée à l'avance : le modèle **le plus simple** dont l'écart avec le meilleur reste sous une erreur standard. Ordre de simplicité : Elastic Net $<$ GAM $<$ SVR $<$ GP $<$ forêt aléatoire $<$ XGBoost, CatBoost, BART.
- **Second critère** : le comportement hors du domaine des données (pour la carte).

Élément clé : pour qu'un modèle soit jugé meilleur qu'un autre, il lui faut de ≈ 0.02 à 0.06 de RMSE d'avance, selon les modèles comparés.

Les références à battre

Référence	RMSE	Gain vs 2.0
$Q_{10} = 2.0$	1.083	—
moyenne des sites	0.980	9.5 %
Hacopian, équation publiée	0.994	8.3 %
Hacopian, réentraîné	**0.963**	**11.1 %**

Équation publiée :
$Q_{10} = 0.109 - 0.0315\,\mathrm{MAT} + 0.0002\,\mathrm{MAP} + 0.411\,\mathrm{pH}$.

- **La moyenne bat déjà 2.0** (-0.103 ± 0.049) : le Q_{10} moyen de nos sites vaut 2.51.
- **L'équation publiée ne généralise pas** : elle bat 2.0 sur ses 70 sites d'origine (0.914 contre 1.118), mais fait moins bien sur les 61 autres (1.124 contre 1.106).
- Hacopian réentraîné ne se distingue pas de la moyenne (-0.017 ± 0.028).

Élément clé : battre 2.0 est facile ; battre la moyenne et Hacopian réentraîné est la vraie difficulté.

Premier tri : quelles variables ont leur place ?

Une variable n'entre dans le modèle que si elle remplit trois critères :

1. **disponible partout** : elle existe en carte mondiale (sinon, pas de carte possible) ;
2. **plausible physiquement** : un moteur possible du Q_{10}, pas un artefact d'échantillonnage ;
3. **exploitable** : sans valeurs manquantes, et non redondante ($|\rho| < 0.8$).

- **12 candidats** : MAT, log MAP, pH, log N, argile, sable, C:N, SWC moyen, SWC été relatif, végétation (3 classes), latitude, longitude.
- Un lien faible **pris isolément** ne suffit pas à exclure une variable : seul, MAP a un coefficient nul, mais $+0.12$ une fois MAT prise en compte (effet masqué).
- Coordonnées gardées (décision de l'équipe), avec une vigilance : elles décrivent surtout la géographie de nos sites.

Élément clé : on ne tranche pas variable par variable : il faut une méthode de sélection rigoureuse.

La régularisation : principe

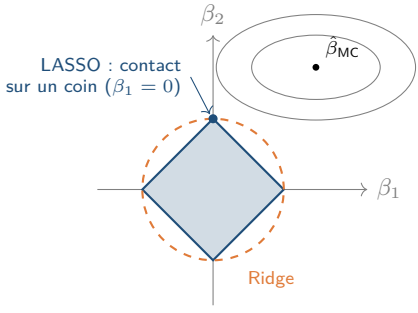
Moindres carrés : $\hat{\beta} = \arg\min_\beta \frac{1}{2n} \sum_i (y_i - x_i^\top \beta)^2$. Avec peu de sites et des variables corrélées, les coefficients sont **instables** (forte variance).

Régulariser : pénaliser la taille des coefficients (variables centrées-réduites) :

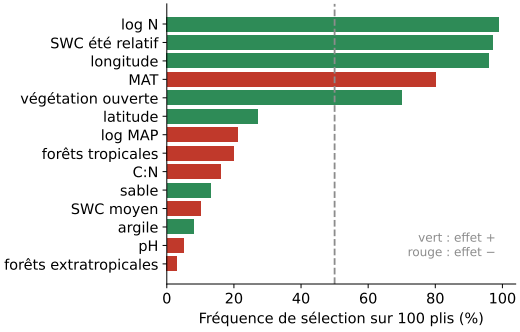
$$\hat{\beta} = \arg\min_\beta \ \frac{1}{2n} \sum_i (y_i - x_i^\top \beta)^2 + \lambda\, P(\beta)$$

- **Ridge** : $P(\beta) = \|\beta\|_2^2 = \sum_j \beta_j^2$, rétrécit tous les coefficients.
- **LASSO** : $P(\beta) = \|\beta\|_1 = \sum_j |\beta_j|$, en met certains **exactement à zéro** : il sélectionne.
- **Elastic Net** : mélange des deux.

λ règle le compromis biais / variance : il est choisi par validation croisée.



LASSO : quelles variables survivent ?



- LASSO refait sur chacun des 100 plis d'entraînement ; λ choisi par validation croisée spatiale **interne**.
- Règle classique « d'un écart-type » : **aucune variable** dans 66 % des plis (signal trop faible). On retient donc le λ qui minimise l'erreur.
- **Noyau stable** (au moins 70 % des plis, signe constant) : N $(+)$, SWC été relatif $(+)$, longitude $(+)$, MAT $(-)$, végétation ouverte $(+)$.
- **Le pH**, central chez Hacopian, n'est retenu que dans 5 % des plis.

Élément clé : cinq variables portent un signal robuste ; c'est cohérent avec Hacopian pour MAT et la végétation, nouveau pour N et l'humidité estivale.

La végétation : un effet indécidable avec nos données

Deux encodages testés (régression Ridge, validation croisée spatiale) :

Végétation ajoutée	RMSE
aucune	**0.934**
typologie en 3 classes	0.955
biomes (7 classes)	0.969

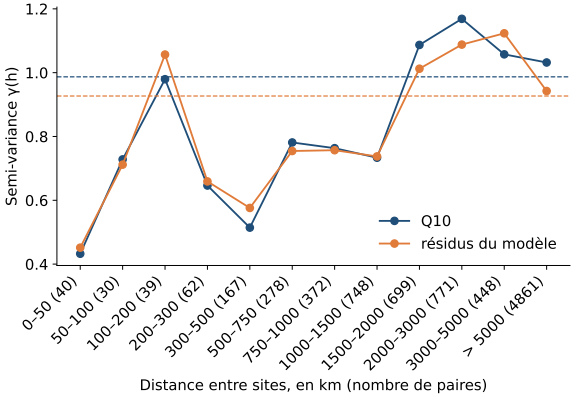
- Le biome décrit la végétation **régionale potentielle**, pas celle de la parcelle (des plantations de pins y sont classées en « prairie »).

Mais un test peu puissant :

- Une fois le climat pris en compte, il reste un écart par biome dans le même sens que chez Hacopian (prairies de montagne $+0.90$, méditerranéen -0.78), non significatif ($p = 0.10$).
- Simulation : si cet effet était réel, notre protocole ne le détecterait que **2 fois sur 3**.
- 47 % des terres sont dans des biomes représentés par un site ou moins.

Élément clé : « pas d'amélioration » ne veut pas dire « pas d'effet » : nos données excluent seulement un effet fort.

Ce que les variables n'expliquent pas



- Semi-variogramme des **résidus** du modèle LASSO : presque identique à celui du Q_{10}.
- La ressemblance entre sites voisins (jusqu'à $\approx 1\,500$ km) **n'est pas expliquée** par le climat ni le sol.
- Elle pourrait venir de facteurs non cartographiés (communautés microbiennes, méthodes de mesure régionales…).

Élément clé : une information spatiale reste à exploiter (krigeage des résidus), mais seulement près de nos sites.

Huit modèles, deux variantes, un protocole

Famille	Modèle	Idée	Hors du domaine
Linéaire / additif	Elastic Net	droite pénalisée	prolonge la tendance
	GAM	somme de courbes lisses	prolonge les courbes
Noyaux	SVR	similarité aux sites	revient vers une constante
	Processus gaussien	krigeage dans l'espace des variables	revient vers la moyenne
Arbres	Forêt aléatoire	moyenne d'arbres	constante
	XGBoost, CatBoost	arbres ajoutés pas à pas	constante
	BART	somme d'arbres bayésienne	constante

- **V1** : les 12 candidats. **V2** : sélection LASSO refaite dans chaque pli d'entraînement, puis le modèle.
- **Validation croisée imbriquée** : les plis externes évaluent ; des plis internes, eux aussi spatiaux, règlent les hyperparamètres.
- Tous les modèles apprennent $\log Q_{10}$ sur exactement les mêmes plis.

Modèles linéaires et additifs

Elastic Net ($y = \log Q_{10}$, variables centrées-réduites) :

$$\hat{\beta} = \arg\min_{\beta_0,\beta} \frac{1}{2n} \sum_{i=1}^{n} \left(y_i - \beta_0 - x_i^\top \beta\right)^2 + \lambda\Big(\alpha\|\beta\|_1 + \frac{1-\alpha}{2}\|\beta\|_2^2\Big)$$

λ et α (part du LASSO) choisis par validation croisée spatiale interne. Interprétable : un coefficient par variable.

Modèle additif généralisé (GAM) : chaque variable agit par une courbe lisse,

$$y_i = \beta_0 + \sum_j f_j(x_{ij}) + \varepsilon_i, \qquad f_j(x) = \sum_{k=1}^{8} b_{jk}\, B_k(x) \quad \text{(splines)}$$

ajustée en minimisant $\sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j \int f_j''(x)^2\, dx$: la pénalité de courbure empêche les courbes d'osciller. Capte des effets non linéaires (seuils) en restant lisible.

Élément clé : hors du domaine des données, ces modèles prolongent leur tendance : sur l'échelle de Q_{10}, une droite en log devient une exponentielle.

Méthodes à noyau : SVR et processus gaussien

SVR : prédiction = somme pondérée de similarités aux sites, $f(x) = \sum_i \alpha_i \, k(x_i, x) + b$, avec $k(x, x') = e^{-\gamma \|x - x'\|^2}$.

$$\min_f \ \tfrac{1}{2}\|f\|^2 + C \sum_i \max\big(0, \ |y_i - f(x_i)| - \epsilon\big)$$

Les erreurs de moins de ϵ sont ignorées ; C, γ, ϵ réglés par validation croisée interne. Loin de tous les sites, $f(x) \to b$.

Processus gaussien (GP) : a priori $f \sim \mathcal{GP}(0, k)$, avec une échelle ℓ_j par variable :

$$k(x, x') = \sigma_f^2 \exp\Big(-\tfrac{1}{2} \sum_j \frac{(x_j - x'_j)^2}{\ell_j^2} \Big) + \sigma_n^2 \, \delta_{xx'}, \qquad \hat{f}(x_*) = k_*^\top \, (K + \sigma_n^2 I)^{-1} \, y$$

Hyperparamètres par maximum de vraisemblance marginale. Donne aussi une variance de prédiction.

Élément clé : le GP est l'analogue du **krigeage**, mais dans l'espace des variables explicatives plutôt que dans l'espace géographique.

Ensembles d'arbres

Arbre de régression : découpe l'espace des variables en rectangles, avec une valeur constante par rectangle.

- **Forêt aléatoire** : $\hat{f}(x) = \frac{1}{B}\sum_{b=1}^{B} T_b(x)$. Chaque arbre est entraîné sur un tirage avec remise des sites, avec un sous-ensemble aléatoire de variables à chaque coupure. La moyenne réduit la variance.
- **Boosting** (XGBoost, CatBoost) : arbres ajoutés un à un, chacun corrigeant les résidus des précédents,

$$F_m(x) = F_{m-1}(x) + \eta\, h_m(x), \qquad \min \sum_i \ell(y_i, F(x_i)) + \sum_m \Big(\gamma T_m + \tfrac{1}{2}\lambda \|w_m\|^2\Big).$$

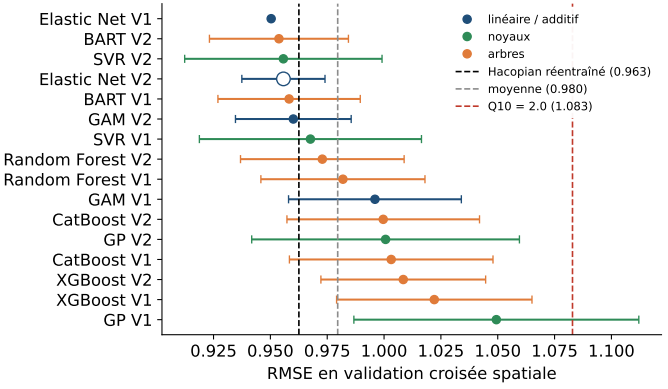
- **BART** : somme de petits arbres, avec des lois a priori qui limitent la contribution de chacun,

$$y = \sum_{m=1}^{M} g(x;\, T_m, \mu_m) + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \sigma^2),$$

estimée par MCMC : prédiction moyenne et intervalles de crédibilité.

Élément clé : flexibles et capables de capter des interactions, mais gourmands en données ; hors du domaine des données, leur réponse est plate.

Seize configurations sur les mêmes plis



Barres : ± une erreur standard de l'écart à la meilleure configuration.

- Meilleure : Elastic Net V1 (0.950).
- **10 configurations équivalentes** (écart sous une erreur standard) : notre protocole ne peut pas les départager.
- Règle de choix : **Elastic Net V2** (0.956, -11.7 % par rapport à 2.0), le plus simple.
- Boosting, CatBoost et GP font **moins bien que la moyenne**.

Élément clé : avec 131 sites, la complexité ne paie pas : les modèles linéaires et additifs font au moins aussi bien.

Ce que vaut vraiment ce gain

Elastic Net V2 face aux références (écart $\pm$ erreur standard) :

contre	écart	plis gagnés
$Q_{10} = 2.0$	-0.127 ± 0.056	92 %
moyenne	-0.024 ± 0.059	66 %
Hacopian réentraîné	-0.007 ± 0.062	58 %

- Le gain sur 2.0 ($\approx$ 12 %) est **net**.
- Mais **9.5 points** viennent du seul niveau moyen (2.51 sur nos sites).
- Le supplément apporté par les variables ($\approx$ 2 à 3 points) ne se distingue ni de la moyenne ni de Hacopian réentraîné.
- $R^2 \leq 0.013$ pour tous les modèles en régions nouvelles.

Sélection en amont (V2 contre V1) : elle aide ou est neutre pour tous les modèles (GAM : -0.036 ± 0.033), sauf l'Elastic Net, qui sélectionne déjà lui-même.

Élément clé : battre 2.0 : oui. Mieux prédire les variations du Q_{10} d'une région à l'autre : très peu, avec ces données.

Trois R^2, trois questions différentes

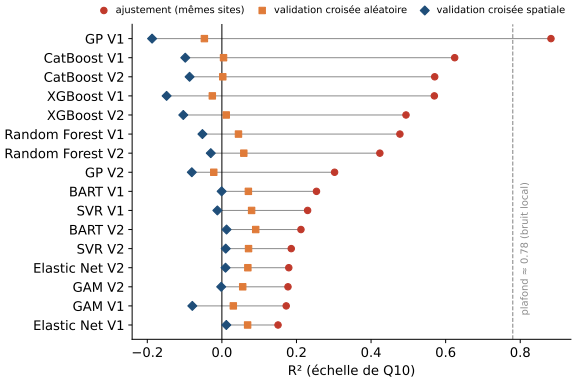
$$R^2 = 1 - \frac{\sum_i (Q_{10,i} - \widehat{Q_{10,i}})^2}{\sum_i (Q_{10,i} - \overline{Q_{10}})^2}$$ (0 pour la moyenne ; négatif si l'on fait moins bien qu'elle)

R^2 calculé sur…	Question posée	Ce qu'il mesure
les sites d'entraînement (**ajustement**)	le modèle décrit-il ses données ?	le **pouvoir explicatif**, celui des articles (Hacopian : $R^2 \approx 0.15$)
des sites retirés au hasard (**VC aléatoire**)	prédit-il un site dont les voisins sont connus ?	l'interpolation
des régions retirées (**VC spatiale**)	prédit-il une région jamais vue ?	le **pouvoir prédictif** utile pour la carte

- **Plafond** : le bruit local entre mesures d'un même site limite le R^2 atteignable à ≈ 0.78.
- r^2 (carré de la corrélation entre observé et prédit) : mesure seulement si le modèle **classe** les sites dans le bon ordre, sans pénaliser un décalage ou une mauvaise échelle.

Élément clé : un R^2 d'ajustement élevé ne garantit rien pour des régions nouvelles.

Pouvoir explicatif contre pouvoir prédictif



- **Ajustement** : jusqu'à 0.88 (GP V1), **au-dessus du plafond** : le modèle apprend le bruit par cœur. Arbres : 0.42 à 0.62. Modèles retenus : 0.15 à 0.21.
- **VC aléatoire** : au mieux 0.09 (BART V2, Elastic Net ≈ 0.07).
- **VC spatiale** : au mieux 0.013 ; négatif pour les modèles flexibles.
- r^2 spatial jusqu'à 0.08 : les modèles classent un peu les sites, mais leurs prédictions restent trop proches de la moyenne.

Élément clé : l'ordre s'inverse : plus un modèle explique ses propres sites, moins il prédit les régions nouvelles.

Augmenter les données avec une copule ?

Théorème de Sklar : toute loi jointe se sépare en marginales et en dépendance,

$$F(x_1, \ldots, x_d) = C\big(F_1(x_1), \ldots, F_d(x_d)\big).$$

Copule gaussienne :
$C_P(u) = \Phi_P\big(\Phi^{-1}(u_1), \ldots, \Phi^{-1}(u_d)\big)$.
Génération : $z \sim \mathcal{N}(0, P)$, $u_j = \Phi(z_j)$, $x_j = \hat{F}_j^{-1}(u_j)$. La copule est ajustée sur les seuls sites d'entraînement de chaque pli.

	Ridge	Forêt
sites réels	**0.933**	1.000
+ 131 synthétiques	0.954	0.988
+ 1 000 synthétiques	0.973	0.971

- Le Ridge se dégrade ; à pénalité égale, l'effet disparaît ($+0.004 \pm 0.012$).
- La forêt s'améliore un peu, sans dépasser une erreur standard : simple effet de régularisation.

Élément clé : un générateur ajusté sur nos sites n'en sait pas plus qu'eux : aucune information nouvelle. Piste écartée.

Une grille mondiale cohérente avec l'entraînement

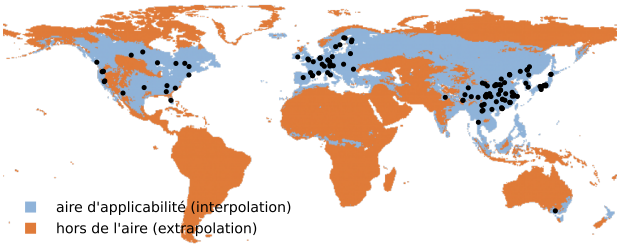
- Grille régulière de $0.5°$ (de 90° N à 60° S) : **64 745 cellules**, avec les mêmes sources et les mêmes définitions qu'à l'entraînement ; valeur d'une cellule = moyenne sur la cellule ($\approx$ 55 km).
- **Concordance aux sites** (valeur du site contre valeur de sa cellule) : corrélations de 0.92 (SWC moyen) à 0.99 (MAT, pH) ; 95 % des sites ont la même classe de végétation que leur cellule.

Mais la grille sort largement de notre domaine :

- MAT de nos sites : -5.2 à 24.5 °C ; sur la grille : -22.2 à 33.5 °C. MAT seule est hors de la plage sur **38 %** des terres.
- **64 %** des terres ont au moins une variable hors de la plage observée.

Élément clé : passer du site à la maille de 0.5° change peu les variables ; le vrai problème est l'extrapolation.

Où le modèle extrapole-t-il ? L'aire d'applicabilité



Meyer et Pebesma (2021), dans l'espace centré-réduit des 6 variables du modèle retenu :

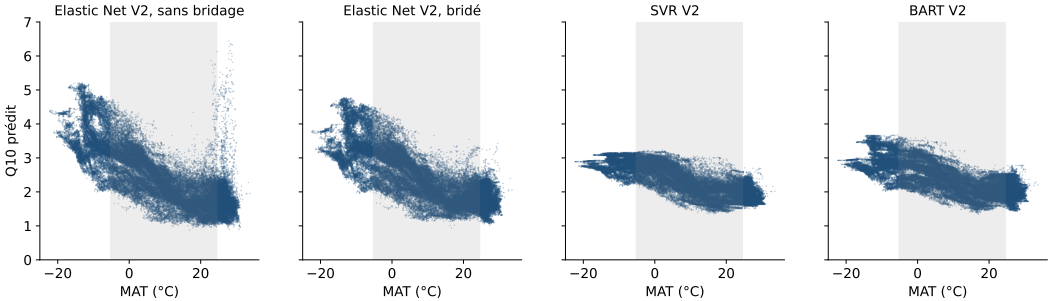
$$\mathrm{DI}(x) = \frac{\min_i \|z(x) - z_i\|}{\bar{d}}$$

($\bar{d}$: distance moyenne entre sites).
Seuil : $Q_3 + 1.5\,\mathrm{IQR}$ des DI des sites, calculés par rapport aux autres zones.

- **36 % des terres** sont dans l'aire d'applicabilité.

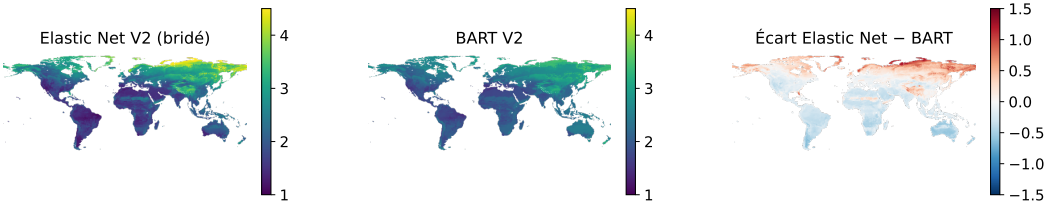
Élément clé : l'Amérique du Sud, l'Afrique, l'Australie intérieure, l'Arctique et la Sibérie sont des extrapolations.

Comment les modèles extrapolent



- Zone grisée : plage de MAT de nos sites. L'Elastic Net prolonge la tendance (Q_{10} plus élevé au froid) ; SVR et BART s'aplatissent.
- **Artefact** : pics jusqu'à 6.4 au Sahara. « SWC été relatif » y divise deux humidités quasi nulles ($\approx$ 0.001 m^3/m^3) et devient du bruit.
- **Correction : le bridage** $\tilde{x}_j = \min\left(\max(x_j, \min_i x_{ij}), \max_i x_{ij}\right)$. Il supprime l'artefact (maximum au Sahara : 6.40 $\rightarrow$ 2.68) et améliore même légèrement la validation croisée (0.956 $\rightarrow$ 0.950).

Là où le choix du modèle compte



- **Dans l'aire d'applicabilité**, les modèles s'accordent (Q_{10} moyen ≈ 2.4).
- **Q_{10} moyen mondial** : 2.1 à 2.2 selon le modèle, proche de 2.0.
- **Régions froides** (10 % des terres, aucun site) : Elastic Net 3.40, BART 2.92, SVR 2.82, Hacopian 2.97.

Élément clé : la carte apporte surtout une **répartition** du Q_{10} ; l'incertitude est maximale là où se trouve le permafrost.

Nos hypothèses, confrontées aux résultats

Hypothèse	Verdict
H1 — Q_{10} prévisible depuis des cartes	**en partie** : signal robuste mais faible ($R^2 \approx 0$ en régions nouvelles)
H2 — plus de variables aident	**en partie** : N et SWC été relatif entrent dans le noyau ; le pH n'y survit pas
H3 — le ML flexible bat le linéaire	**non** : linéaire et additif en tête ; boosting et GP sur-apprennent (R^2 d'ajustement jusqu'à 0.88, R^2 spatial négatif)
H4 — les données synthétiques compensent	**non** : aucune information nouvelle
H5 — les coordonnées sont utiles	**oui pour la longitude** (effet Asie de l'Est) ; origine à éclaircir
H6 — le biome est un bon prédicteur	**indécidable** avec nos données (test peu puissant)

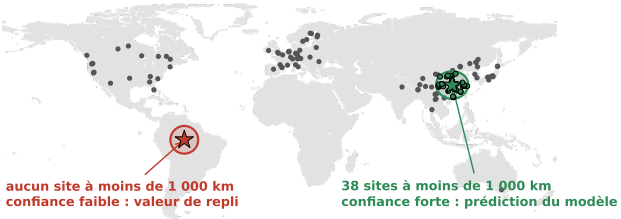
Ce que nous avons appris

1. **Les données sont le facteur limitant** : 131 sites concentrés sur trois régions ; le modèle extrapole sur 64 % des terres.
2. **Battre 2.0 est facile, mais surtout par le niveau moyen.** Les variables n'ajoutent que 2 à 3 points, ce qui ne se distingue ni de la moyenne ni de Hacopian réentraîné.
3. **Les modèles simples gagnent** : les plus flexibles expliquent jusqu'à 88 % de la variance de leurs propres sites, mais rien dans des régions nouvelles.
4. **Signaux robustes** : azote, sécheresse estivale, MAT, effet Asie de l'Est, végétation ouverte.
5. **L'incertitude de la carte vient de l'extrapolation**, et elle est maximale dans les régions froides.

Limites de notre approche

- **Représentativité** : aucun site plus froid que -5.2 °C, aucun en Afrique ni en Amérique du Sud. Le Q_{10} moyen de nos sites (2.51) n'est pas forcément celui de la planète.
- **Hétérogénéité des mesures** : méthodes de séparation des respirations, plages de température et durées différentes d'une étude à l'autre. Aucun biais net par source, mais un bruit qui s'ajoute.
- **Végétation** : le biome décrit la végétation potentielle, pas celle de la parcelle.
- **Échelle** : un Q_{10} de parcelle prédit à l'échelle d'une maille de 0.5° (concordance des variables vérifiée, mais le Q_{10} lui-même peut dépendre de l'échelle).
- **Puissance statistique** : avec 131 sites, des effets modérés (biome, interactions) restent indétectables.
- **Longitude** : son effet peut refléter des pratiques de mesure régionales autant qu'un vrai signal ; il reste figé si le climat change.

Proposition : un niveau de confiance et une valeur de repli



- **Confiance** : $c(x) = \min\left(1,\, n_r(x)/n^*\right)$, où $n_r(x)$ est le nombre de sites à moins de $r \approx 1\,000$ km (portée du semi-variogramme).
- **Règle** : prédiction du modèle si $c(x) \geq \alpha$; sinon **valeur de repli** : 2.0, ou une valeur propre à la zone.
- **Sans saut** : $c\,\hat{f} + (1-c)\,Q_{10}{}^{\text{repli}}$.
- **Aujourd'hui** : 30 % des terres ont au moins un site à moins de 1 000 km ; 13 % en ont au moins cinq.

Élément clé : la carte prédirait là où elle dispose d'informations (en combinant cette confiance avec l'aire d'applicabilité), et reviendrait à une valeur prudente ailleurs.

Pistes à explorer

- **Ajouter des sites là où ils manquent**, en priorité les régions froides et tropicales : c'est le levier le plus puissant.
- **Végétation réelle** : occupation du sol satellitaire (MODIS) ou PFT d'ORCHIDEE à la place du biome.
- **Modèle hiérarchique** : effet aléatoire par classe de végétation, qui rétrécit les effets des petits groupes au lieu de les ignorer.
- **Krigeage des résidus** : exploiter la structure spatiale non expliquée, près des sites.
- **Carte d'incertitude** : intervalles de crédibilité du BART, combinés à l'aire d'applicabilité.
- **Q_{10} dynamique** : une relation $Q_{10} = f(\text{climat})$ utilisable dans les scénarios.
- **Au-delà du Q_{10}** : Hacopian montre que le modèle MMRT décrit mieux la réponse à la température.

Annexe — Les 16 configurations

Configuration	RMSE	Gain vs 2.0
Elastic Net V1	0.950	12.2 %
BART V2	0.954	11.9 %
SVR V2	0.956	11.7 %
Elastic Net V2	**0.956**	**11.7 %**
BART V1	0.958	11.5 %
GAM V2	0.960	11.3 %
Hacopian réentraîné	*0.963*	*11.1 %*
SVR V1	0.968	10.6 %
Forêt aléatoire V2	0.973	10.2 %
moyenne	*0.980*	*9.5 %*

Configuration	RMSE	Gain vs 2.0
Forêt aléatoire V1	0.982	9.3 %
Hacopian publié	*0.994*	*8.3 %*
GAM V1	0.996	8.0 %
CatBoost V2	1.000	7.7 %
GP V2	1.001	7.6 %
CatBoost V1	1.003	7.4 %
XGBoost V2	1.008	6.9 %
XGBoost V1	1.022	5.6 %
GP V1	1.049	3.1 %
$Q_{10} = 2.0$	*1.083*	—

Annexe — Réglages des modèles

Modèle	Réglés par validation croisée spatiale interne	Autres choix
Elastic Net	λ (10 valeurs), part du LASSO $\alpha \in \{0.1, 0.5, 0.9\}$	—
GAM	pénalité de courbure (5 valeurs)	8 splines par variable
SVR	C, γ, ϵ (36 combinaisons)	noyau gaussien
GP	par vraisemblance marginale	une échelle par variable
Forêt aléatoire	variables par coupure, taille des feuilles	200 arbres
XGBoost	profondeur, pénalité λ	300 arbres, $\eta = 0.03$
CatBoost	profondeur, pénalité ℓ_2	300 arbres, $\eta = 0.05$
BART	aucun (lois a priori par défaut)	500 tirages MCMC conservés

Grilles volontairement petites : 131 sites, 100 plis externes, plis internes eux aussi spatiaux.

Annexe — Sélection LASSO sur 100 plis

Variable	Fréquence	Signe	Variable	Fréquence	Signe
log N	99 %	+	C:N	16 %	−
SWC été relatif	97 %	+	sable	13 %	+
longitude	96 %	+	SWC moyen	10 %	mixte
MAT	80 %	−	argile	8 %	mixte
végétation ouverte	70 %	+	pH	5 %	−
latitude	27 %	+	forêts extratropicales	3 %	−
log MAP	21 %	−			
forêts tropicales	20 %	−			

LASSO avec la pénalité qui minimise l'erreur de la validation croisée spatiale interne ; médiane de 5 variables retenues par pli. Performance : RMSE 0.954 (Ridge sur toutes les variables : 0.953).